




Pipeline de dados em Nuvem para classificação de aves através do som

Afrain da Silva Calixto
Flávio Lourenço da Silva
Gustavo Adolpho Souteras Barbosa


Prof. Dr. Sirlon Diniz
Prof. Dr. Raphael Gomes
Prof. Dr. Otávio Calaça

5 de agosto de 2026



Resumo

O presente documento descreve os procedimentos adotados para implementar uma solução de Inteligência Artificial para classificação de aves através do som. O projeto contempla a construção de um pipeline de dados completo, da coleta e organização de dados à geração de análises, previsões e visualizações para o usuário final.



1 Introdução

1.1 Objetivos do projeto interdisciplinar

A atividade final do Segundo Módulo do curso de Pós-graduação em Inteligência Artificial Aplicada trata-se de um projeto integrado onde cada grupo deverá desenvolver de forma interdisciplinar uma solução de IA (Inteligência Artificial) aplicada ao apoio à decisão, combinando os conhecimentos trabalhados nas disciplinas deste Módulo.

O projeto deve contemplar a construção de um pipeline completo, da coleta e organização dos dados à geração de análises, predições e visualizações para o usuário final. Para tanto, o grupo deve utilizar dados estruturados e pelo menos uma fonte de dados não estruturados ou semiestruturados. A solução deve armazenar os dados brutos em ambiente de nuvem, processá-los e transformá-los em atributos tabulares, carregá-los em uma base analítica e aplicar técnicas aprendidas durante o Segundo Módulo. O grupo é livre para escolher seus próprios conjuntos de dados, detalhando o domínio de aplicação, usuário ou tomador de decisão, decisão apoiada, fontes de dados utilizadas, tarefa de Aprendizado de Máquina e o resultado esperado da solução.

Seguindo estas orientações, o grupo decidiu implementar um projeto de coleta e classificação de sons de aves. Os objetivos específicos deste projeto são detalhados a seguir.

1.2 Objetivos específicos do projeto desenvolvido

Segundo **Carvalho e Gomes [1]**, a identificação de espécies de aves é uma tarefa importante para ornitologistas e ecologistas. O comportamento e tendências de população de aves permite a detecção de outros organismos no ambiente, uma vez que as aves reagem rapidamente a alterações ambientais. **Márquez-Rodríguez et al. [2]** menciona que o monitoramento da presença de pássaros é crucial, já que estes servem como indicadores da saúde do ecossistema.

Este monitoramento é feito atualmente através de câmeras e gravadores de áudio[2], mas gerenciar e analisar o grande volume de dados obtido é desafiador. É neste contexto que a classificação de aves empregando ferramentas de aprendizado de máquina ganha cada vez mais importância na comunidade científica.

O objetivo específico deste trabalho é portanto desenvolver uma ferramenta de classificação de canto de aves. Esta ferramenta pretende auxiliar profissionais da área de ecologia a identificar a presença ou não de espécies de aves através de seu canto e permitir com isto uma ação mais rápida, quando necessário.

O projeto desenvolvido, para este fim, obtém vários arquivos de gravações de pássaros de um servidor de forma automatizada. Estes arquivos serão transferidos para um Bucket S3 da Amazon, processados para se obter várias características necessárias para o treinamento de um classificador MLP (*Multi-Layer Perceptron*).

O classificador deve ser capaz de identificar um tipo de ave dentre vários tipos. Para a implementação deste projeto a ave escolhida foi o bem-te-vi (*Pitangus sulphuratus*).

2 Fundamentação teórica

2.1 Processamento digital de áudio

Sons coletados na natureza são sinais contínuos no tempo, portanto, constituído de infinitos instantes. Para poder ser armazenado e processado, este tipo de sinal precisa passar por um **processo de amostragem**, onde periodicamente a amplitude do sinal é amostrada e seu valor digital é armazenado. A frequência que estas amplitudes são amostradas é a **taxa de amostragem** do sinal.

Este sinal digital é então convertido em algum formato de áudio, como o arquivo *.wav* para áudio não compactado. O formato de áudio compactado mais conhecido é o formato *.mp3*. Todos os arquivos trabalhados no projeto se encontram em formato *.mp3*. Estes serão convertidos ou processados por funções da biblioteca de processamento de áudio *librosa* no *python*.

A taxa de amostragem é uma das características que podem ser obtidas do sinal digital. Outras características podem ser obtidas a partir deste sinal e que são geralmente empregadas em aplicações de reconhecimento ou classificação.

2.1.1 FTT

A Transformada rápida de Fourier (FTT, do inglês *Fast Fourier Transform*) é um algoritmo que calcula de forma eficiente a Transformada Discreta de Fourier (DFT do inglês *Discrete Fourier Transform*) e descrito a primeira vez em um artigo de Cooley e Tukey em 1965 [3]. Ele reduz a complexidade do DFT de $O(n^2)$ para $O(n * \log(n))$, onde n é o tamanho dos dados.

A FFT converte um sinal representado no domínio do tempo em um sinal com representação no domínio da frequência, como pode ser visto na **Figura 1**:




Figura 1: Conversão de domínio do tempo em domínio da Frequência.

Fonte: NTi Audio[4]

Na **Figura 1** o sinal dentro do período representado é convertido em uma representação no domínio da frequência onde pode-se distinguir 3 frequências dominantes.

É importante destacar que a FFT assume que o segmento do sinal aplicado é de um sinal que se repete periodicamente por um tempo infinito. Por isto conclui-se que a FFT é adequada apenas a sinais periódicos e o sinal deve conter períodos completos do sinal. Isto nem sempre é praticável, por isto algumas medidas costumam ser adotadas antes da FFT ser aplicada em um sinal.

2.1.2 Janelamento (Windowing)

Para um correto emprego de FFT sobre um sinal, o sinal amostrado deve representar períodos completos do sinal. Se o sinal apresentar cortes abruptos no sinal, o fenômeno conhecido por **vazamento espectral ocorre**: a energia de uma frequência pura é espalhada por várias frequências adjacentes, gerando-se várias frequências falsas no sinal.

Na prática é difícil começar ou terminar a amostragem de um sinal exatamente no início do período deste. Para permitir a aplicação da FFT em qualquer tipo de sinal, emprega-se a técnica de Janelamento (**Windowing** em inglês). Esta técnica consiste em multiplicar ponto a ponto um sinal chamado Janela ao sinal desejado, resultando em um sinal que se inicia e termina em 0 V.




Figura 2: Aplicação da Janela de Hamming a um sinal.

Fonte: NTi Audio[5]

A **Figura 2** exemplifica o emprego de uma janela de Hamming para suavizar o início e final de um sinal senoidal. Deve-se observar que esta janela deve ser de mesma duração do sinal amostrado. Outras janelas

conhecidas são a retangular, a janela de Hanning, a triangular, a Blackman e a Kaiser. Uma comparação entre elas pode ser vista na Figura 3:




Figura 3: Tipos de sinais de janela.

Fonte: Dah-Jing Jwo et al.[6]

2.1.3 STFT e espectrograma

Aplicar uma FFT em um sinal completo apresenta dois problemas principais. O primeiro é que o ciclo de multiplicações soma que faz parte do algoritmo exigirá maior esforço computacional. O segundo problema é que frequências de todo o sinal serão representadas no mesmo resultado, não sendo possível então identificar se uma determinada frequência estava presente apenas em parte do sinal, no começo por exemplo, ou em todo o sinal.

Com estes pontos em mente, desenvolveu-se a **Transformada de Fourier de Tempo Curto**[7] (STFT do inglês *Short Time Fourier Transform*), que se baseia na FFT. Este algoritmo analisa o sinal através de fragmentos de duração do sinal completo, chamados aqui de quadros. A estes quadros são aplicadas a técnica descrita na **Seção 2.1.2** e então é computada a FFT.

O quadro então é avançado no tempo e então o procedimento é feito novamente, até todo o sinal ser analisado. Este avanço é feito no máximo por um quadro, mas o comum é que se avance metade de um quadro, para que a análise resultante não seja muito brusca.

O resultado desta operação é normalmente exibido em um gráfico de espectro de potência x frequência x tempo, conhecido como **espectrograma**. O espectrograma STFT de um dos sinais analisados durante o trabalho pode ser visto na **Figura 5**. A escala de cores exibe a potência naquela frequência, o eixo y descreve as frequências e o eixo x traz o tempo durante o áudio.

2.1.4 Coeficiente Cepstral de Frequência Mel

O algoritmo mais empregado na análise de sinais sonoros é o Coeficiente de Cepstro de Frequência Mel (MFCC do inglês, *Mel Frequency Cepstrum Coefficient*). Enquanto algoritmos como o FTT capturam harmônicos e bandas laterais de um sinal no domínio do tempo, este algoritmo é capaz de extrair harmônicos e bandas laterais da versão espectral do sinal[8].

Os passos para calcular os coeficientes MFCC são apresentados na **Figura 4**:




Figura 4: Passos para o cálculo do MFCC.

Fonte: Mel Frequency Cepstral Coefficient and its Applications: A Review[8]

No estágio de pré-ênfase, aplica-se um filtro passa alta no sinal, para compensar a supressão de componentes de alta frequência durante a produção do sinal. Isto altera a distribuição de energia do sinal em todas as frequências.

Depois aplica-se a técnica descrita na seção 2.1.2. O tamanho de quadro escolhido depende da aplicação. Por exemplo um tamanho comum para reconhecimento de fala é de 20 a 30 ms, já que o intervalo glotal é de aproximadamente 20 ms.

O próximo passo é passar o sinal por um banco de filtros passa-banda Mel, por convenção sendo constituído de 40 filtros triangulares. Este banco de filtros foi construído com base na percepção tonal. O filtro Mel foi originalmente desenvolvido para análise de fala e, tal qual a percepção auditiva humana, tem como objetivo extrair uma representação não linear do sinal de fala. Por isto cada filtro soma a energia de uma faixa de frequências e o resultado é convertido para escala logarítmica.

O passo final é aplicar uma transformada discreta de cossenos (DCT, do inglês *Discrete Cosine Transform*). No processo de MFCC, a DCT é aplicada ao banco de filtros Mel para selecionar os coeficientes mais relevantes (ou mais acelerativos) ou para separar as relações existentes nas magnitudes logarítmicas do espectro provenientes do banco de filtros.

A **Figura 5** mostra um sinal usado neste trabalho, acompanhado por seu espectrograma STFT e Mel.






Figura 5: Espectrogramas do canto de um bem-te-vi.
Fonte: os próprios autores



3 Materiais e Métodos


3.1 Fonte de dados

Este trabalho é facilitado pela cada vez maior disponibilidade de dados sobre pássaros. Um bom exemplo de base de dados é a base da Xeno-Canto[9], que disponibiliza um enorme banco de gravações de cantos de pássaros, todas elas já catalogadas.

O usuário, mediante cadastro no site, recebe uma chave que pode ser usada para fazer consultas através de uma API. As consultas retornam arquivos em formato *.json* contendo os dados desejados. Pode-se consultar, por exemplo, quais arquivos de gravações existem para determinadas espécies de pássaros, o que retorna um *array .json* onde cada item possui informações sobre uma gravação das aves consultadas.

Os possíveis parâmetros passados pela resposta em *.json*, fornecidos pela descrição da API[10], são os seguintes:


- **id**: Número de catálogo da gravação no Xeno-Canto.
- **gen**: Nome do gênero da espécie.
- **sp**: Nome específico (epíteto específico) da espécie.
- **ssp**: Nome da subespécie (epíteto subespecífico).
- **grp**: Grupo ao qual a espécie pertence (aves, gafanhotos, morcegos etc.).
- **status**: Status de identificação da gravação (a espécie principal pode estar identificada como não identificada, questionada ou não confirmada).
- **en**: Nome da espécie em inglês.
- **rec**: Nome do responsável pela gravação.
- **cnt**: País onde a gravação foi realizada.
- **loc**: Nome da localidade da gravação.
- **lat**: Latitude da gravação em coordenadas decimais.
- **lng**: Longitude da gravação em coordenadas decimais.
- **type**: Tipo de vocalização da gravação (combinando termos predefinidos, como “canto” ou “chamado”, com descrições em texto livre).
- **sex**: Sexo do animal.
- **stage**: Estágio de vida do animal (adulto, juvenil etc.).
- **method**: Método de gravação (em campo, em cativeiro, na mão etc.).
- **url**: URL contendo os detalhes da gravação.
- **file**: URL do arquivo de áudio.



- **file-name:** Nome original do arquivo de áudio.
- **sono:** Objeto contendo as URLs das quatro versões do sonograma.
- **osci:** Objeto contendo as URLs das três versões do oscilograma.
- **lic:** URL que descreve a licença da gravação.
- **q:** Classificação atual da qualidade da gravação.
- **length:** Duração da gravação em minutos.
- **time:** Horário em que a gravação foi realizada.
- **date:** Data em que a gravação foi realizada.
- **uploaded:** Data em que a gravação foi enviada ao Xeno-Canto.
- **also:** Vetor contendo as espécies identificadas ao fundo da gravação.
- **rmk:** Observações adicionais fornecidas pelo responsável pela gravação.
- **animal-seen:** Indica se o animal gravado foi observado visualmente.
- **playback-used:** Indica se foi utilizado *playback* para atrair o animal.
- **temp:** Temperatura durante a gravação (aplicável apenas a grupos específicos).
- **regnr:** Número de registro do espécime (quando coletado).
- **auto:** Indica se a gravação foi realizada automaticamente (sem supervisão).
- **dvc:** Equipamento de gravação utilizado.
- **mic:** Microfone utilizado.
- **smp:** Taxa de amostragem do áudio.
- **annotation-set:** Conjunto de anotações associado à gravação; neste caso, conforme o esquema Annota-JSON.

Para o presente trabalho, o principal parâmetro é a URL do arquivo de áudio, que fornece os dados não estruturados do projeto. Além deste, é interessante obter também gênero, nome específico, nome da subespécie e grupo, pois estes são os dados de saída que deverão ser usados no treinamento. Outros dados semi-estruturados são importantes também, como latitude e longitude da gravação, que pode excluir grupos de aves que dificilmente seriam encontrados em algumas regiões. Qualidade da gravação também é um parâmetro interessante pois gravações com pior qualidade podem produzir erros maiores.

Aqui poderia se obter também detalhes do arquivo de som como duração e taxa de amostragem, mas isto será feito na fase de processamento de dados na camada prata. Esta fase envolve também a geração de coeficientes



Referências

- [1] S. Carvalho and E. F. Gomes, “Automatic classification of bird sounds: Using mfcc and mel spectrogram features with deep learning,” *Vietnam Journal of Computer Science*, vol. 10, no. 01, pp. 39–54, 2023. Disponível em: <https://doi.org/10.1142/S2196888822500300>, acesso em: 27 de julho de 2026.
- [2] A. Márquez-Rodríguez, M. Ángel Mohedano-Munoz, M. J. Marín-Jiménez, E. Santamaría-García, G. Bastianelli, P. Jordano, and I. Mendoza, “A bird song detector for improving bird identification through deep learning: A case study from doñana,” *Ecological Informatics*, vol. 90, p. 103254, 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1574954125002638>, acesso em: 27 de julho de 2026.
- [3] A. B. Qingkai Kong, Timmy Siau, *Python Programming and Numerical Methods*. Elsevier, 2020.
- [4] NTiAudio, “Fast fourier transformation fft,” 2026. Disponível em: <https://www.nti-audio.com/en/support/know-how/fast-fourier-transformation-fft>, acesso em: 27 de julho de 2026.
- [5] NTiAudio, “Windowing signals,” 2026. Disponível em: https://www.ni.com/docs/en-US/bundle/labwindows-cvi/page/advancedanalysisconcepts/windowing_signals.html, acesso em: 27 de julho de 2026.
- [6] Dah-Jing Jwo, Wei-Yeh Chang e I-Hua Wu, “Windowing techniques, the welch method for improvement of power spectrum estimation,” 2026. Disponível em: <https://www.techscience.com/cmc/v67n3/41590/html>, acesso em: 27 de julho de 2026.
- [7] Brian McFee, “Defining the stft,” 2020. Disponível em: <https://brianmcfee.net/dstbook-site/content/ch09-stft/STFT.html>, acesso em: 27 de julho de 2026.
- [8] Z. K. Abdul and A. K. Al-Talabani, “Mel frequency cepstral coefficient and its applications: A review,” *IEEE Access*, vol. 10, pp. 122136–122158, 2022. Disponível em: <https://ieeexplore.ieee.org/document/9955539>, acesso em: 27 de julho de 2026.
- [9] Xeno-Canto, “xeno-canto: Sharing wildlife sounds from around the world,” 2026. Disponível em: <https://xeno-canto.org/>, acesso em: 27 de julho de 2026.
- [10] Xeno-Canto, “Application programming interface (api v3),” 2026. Disponível em: <https://xeno-canto.org/explore/api>, acesso em: 27 de julho de 2026.